

S - шаг по x и y , B - размер batch. FP32, eval(), inference_mode(), $S_{\text{plane}} = 16$. Conv без bias, ReLU. Огн MAC = 2 FLOPs

1 FLOPs для слоя:

$$F_i = 2 B K_i W_i C_{in,i} C_{out,i} k_i^2$$

Сумма всех Conv:

$$F_{\text{conv}} = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B S^2$$

$$= \cancel{17712} B S^2$$

$$= 17712 B S^2$$

GAP и 2 Linear + bias

$$F_{\text{GAP}} = 512 B \left(\frac{S}{16} \right)^2 = 2 B S^2$$

$$F_{\text{linear}} = 2 B (512 \cdot 256 + 256 \cdot 100) + 356 B =$$

$$= 313700 B$$

$$F(S, B) = B (17714 S^2 + 313700)$$

~~2. F~~

val(),

2. Таблица. Параметры $P = 1040324$, вес записи $4P = 4161296$ байт. Внешний вес сохраняется до конца forward. Операция MaxPool эквивалентна нулю: вес $12BS^2$ вес conv $32BS^2$, вес MaxPool $8BS^2$ и вес индексов $16BS^2$ байт. Итого: $M(S, B) \approx 4161296 + 68BS^2$

$24/BS^2$
 $7/12$
 3

3. График и время. Пусть A - число элементов активации на слое, P_i - число параметров слоя. Треугольная структура имеет веса / весов и число слоев:

$$Q_{conv/linear, i} = 4[B(A_{in, i} + A_{out, i}) + P_i] \quad Q_{ReLU, i} = 8BA_i$$

$$Q_{pool} = 56BS^2 \quad Q_{GAP} = 4B(2S^2 + 512)$$

где цена слоя:

$$Q(S, B) = 380BS^2 + 8592B + 4161296$$

$$T(S, B; \theta) = 17T + \sum_{i=1}^{17} \max\left(\frac{F_i(S, B)}{C}, \frac{Q_i(S, B)}{D}\right)$$

T - число слоев

D - байт / с

C - FLOPS / с

$F_i / Q_i < C / D$ если ограничено

$\theta = (T, C, D)$ набор параметров

используем модель 9 слоев. forward весов 3 параметров

4. Энергия. Тренировка искусственной нейронной сети требует энергии и времени

$$E(s, b; \theta_E) = \lambda F(s, b) + \beta Q(s, b) + P_0 T(s, b, \theta)$$

λ - Φ_{in} / FLOP, β - Φ_{in} / Φ_{mem} , P_0 - Вт; λ и β - коэффициенты, характеризующие энергозатраты на хранение и вычисления в NVM L за цикл W операций за 1 сек

$$E_{real} = \frac{\Delta E_{GPU}}{N}$$

Учитывается вся энергия GPU, idle не учитывается.

Можно учитывать энергию вычислений с DNN, или, наоборот, только энергию хранения; параметры энергии можно быть разными.