

S - шаг по ширине, B - размер batch. FP32, eval(), inference_mode(), Strides 16. Conv без bias, ReLU. Огн MAC = 2 FLOPs

1 FLOPs для слоев:

$$F_i = 2 B K_i W_i C_{in,i} C_{out,i} k_i^2$$

Сумма всех Conv:

$$F_{conv} = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B S^2$$

$$= \cancel{17712} B S^2$$

$$= 17712 B S^2$$

GAP и 2 Linear + bias

$$F_{GAP} = 512 B \left(\frac{S}{16} \right)^2 = 2 B S^2$$

$$F_{linear} = 2 B (512 \cdot 256 + 256 \cdot 100) + 356 B =$$

$$= 313700 B$$

$$F(S, B) = B (17714 S^2 + 313700)$$

~~2. F~~

val(),

2. Параметры. Параметров $P = 1040324$, весов $4P = 4161296$ байт. Внешний вес сохраняется до конца forward. Операции MaxPool эмулируются вручную: вес $12BS^2$ весов conv $32BS^2$, весов MaxPool $8BS^2$ и весов индексов $16BS^2$ байт. Итого: $M(S, B) \approx 4161296 + 68BS^2$

$24/BS^2$
 $7/12$
 3

3. График и время. Пусть A - число элементов активации на слое, P_i - число параметров слоя. Треугольная структура имеет веса / весов и число слоев:

$$Q_{conv/linear, i} = 4[B(A_{in, i} + A_{out, i}) + P_i] \quad Q_{relu, i} = 8BA_i$$

$$Q_{pool} = 56BS^2 \quad Q_{gap} = 4B(2S^2 + 512)$$

где Q - время слоя:

$$Q(S, B) = 380BS^2 + 8592B + 4161296$$

$$T(S, B; \theta) = 17T + \sum_{i=1}^{17} \max\left(\frac{F_i(S, B)}{C}, \frac{Q_i(S, B)}{D}\right)$$

T - число слоев

D - байт / с

C - FLOPS / с

$F_i / Q_i < C / D$ если ограничено

$\theta = (T, C, D)$ подбираем параметры

используем модель 9 слоев. forward весов 3 параметров

4. Энергия. Тренировка искусственной нейронной сети требует энергии и времени

$$E(s, b; \theta_E) = \lambda F(s, b) + \beta Q(s, b) + P_0 T(s, b, \theta)$$

λ - Φ_{in} / FLOP, β - Φ_{in} / Φ_{mem} , P_0 - Вт; λ и β - коэффициенты, характеризующие энергозатраты на Φ_{in} и Φ_{mem} соответственно. T - время работы на GPU за N эпох

$$E_{real} = \frac{\Delta E_{GPU}}{N}$$

Учитывается время работы GPU, idle не считается.

Можно учитывать время работы с DNN, или, наоборот, только время работы с GPU; параметры энергии можно брать из литературы.

Тропка 00M

в цене из 132 морей 00M по форму

Термалу убер. Тем при $S = 512$ на сгн

Tesla Tu Тензона $B = 867$ - время 868-00

$$\text{Boom, prob} = \left\lfloor \frac{6 - 4161296}{68 \cdot 512^2} \right\rfloor + 1 = 872$$

Дур из - за неадекват раскред на дур и ниско
раскред, поэтому 00M возмещен равно